

Detectia stresului din imagini

1st Chelea Diana-Maria
1306B

2nd Spiridon Bianca
1306B

Abstract—Stresul constituie un factor ce afecteaza aspectele cotidiene si influenteaza atat sanatatea mintala, cat si gandirea. Acest proiect abordeaza tehnici de machine learning, utilizand toolkit-ul Dlib, pentru a detecta expresiile faciale din imagini, fiind capabil sa precizeze nivelul de stres al persoanelor. O alta ramura a ML folosita este Deep Learning, care consta in utilizarea de retele neuronale artificiale pentru a prelua caracteristici, adica structuri alcatuite din mai multe straturi, vizibile si ascunse, care transforma imaginea initiala. Partea de cod foloseste biblioteca Python facerecognition, OpenCV si mediul de programare Colab. Pentru inceput, vom prelua un set de imagini de pe site-uri web, iar algoritmul este implementat prin tehnici precum Histogram of Oriented Gradients, care ajuta la identificarea unui obiect in functie de contururi, bazandu-se pe gradientul imaginii, sau Haar Cascades, metoda care analizeaza variatiile pixelilor din subregiuni ale imaginii pentru a determina anumite caracteristici specifice.

Index Terms—recunoastere faciala, ML, retele neuronale

I. INTRODUCERE

Acest fenomen omniprezent in existenta umana este o realitate inevitabila si complexa care ne insoteste in fiecare aspect al vietii noastre. Este important sa intelegem ca cresterea sau intensificarea stresului poate avea un efect negativ, chiar si atunci cand este considerat adaptiv sau normal. Intelegerea si gestionarea acestuia sunt esentiale pe masura ce societatea noastra se schimba si avem ritmuri din ce in ce mai alerte si solicitante. Interesul in cercetare a atins cote considerabile, desfasurandu-se studii in domenii precum neurostiinta, psihologie si medicina. In acest scop, s-au conturat diverse solutii. Aceste solutii variaza de la strategii de adaptare personala, pana la implementarea unor tehnologii ce pot detecta stresul. Scopul acestei lucrari este de a dezvolta si a implementa un program pentru detectarea stresului in imagini, punand accent pe analiza expresiilor faciale. Prin utilizarea tehnologiilor de recunoastere faciala si al algoritmilor deep learning, intentionam sa identificam caracteristici faciale specifice, asociate starii de stres. Ne propunem sa dezvoltam un instrument precis, capabil sa ofere o evaluare obiectiva a stresului. Prin imbinarea tehnologiei cu intelegerea profunda a comportamentului uman, aceasta lucrare va ajuta in cercetarea stiintifica, dar si in implementarea unor solutii practice pentru prevenirea stresului. Proiectarea si implementarea acestui program ar include: procesul de colectare a datelor, preprocesarea fotografiilor: redimensionarea si normalizarea imaginilor pen-

tru a garanta coerenta si eficienta analizei, implementarea algoritmului de identificare a fetei, selectarea unui model de deep learning (CNN) pentru extragerea caracteristicilor fetei, utilizarea unui model machine learning pentru a urmari coordonatele sprancenei, testarea algoritmului si analiza expresiilor faciale in contextul stresului.

II. STATE-OF-THE-ART

Diversele abordari si implementari care au fost dezvoltate si aplicate in ultimii ani au imbunatatit semnificativ procesul de identificare si evaluare a stresului prezent in imagini. Ca exemplu, acestea includ:

A. Retele neuronale CNN


Retelele neuronale extrag caracteristicile fetelor din imagini pentru recunoasterea faciala. Acest lucru le permite sa distinga diferite persoane din imagini noi. CNN contine: input layer, hidden layers si output layer, toate conectate intre ele. Primul nivel accepta intrari in diferite forme, straturile ascunse le prelucraza, iar layerul de iesire contine rezultatul final.

1. Convolution layer: rezultatele filtrarii imaginii initiale (peste imaginea de intrare se aplica filtre, pentru a evidentia obiecte).

Formula dupa care se calculeaza convolutia:


$$s(i,j) = (X \times W)(i,j) + b = \sum_{k=1}^{n_{in}} (X_k \times W_k)(i,j) + b$$

Convolutie:



2.Pooling layer: reprezinta layerul obtinut prin micșorarea imaginii de intrare, ajuta la pastrarea caracteristicilor relevante. De exemplu, max pooling reduce dimensiunea selectand valoarea maxima dintr-o regiune specifica.

Pooling:



Scopul convolutiei si al pooling-ului este de a reduce progresiv volumul datelor si de a extrage elemente care devin tot mai abstracte in straturile ulterioare ale retelei.

3.ReLU: reprezinta layerul Rectified Linear Unit. Astfel, daca valorile din matrice sunt mai mici decat 0, clar pixelii nu sunt relevanti pentru cautare, deci ii vom ignora, atribuindu-le valoarea 0.

B. The Histogram of Oriented Gradients

The Histogram of Oriented Gradients este o tehnica de extragere a caracteristicilor din imagini, utilizata pentru detectia de obiecte sau recunoastrea lor in imagini . Aceasta tehnica numara aparitiile orientarii gradientului intr-un segment specific al unei imagini. Descriptorul HOG se concentreaza pe forma sau structura unui obiect. Deoarece calculeaza caracteristicile utilizand atat magnitudinea, cat si unghiul gradientului, aceasta tehnica este mai eficienta decat orice descriptor de margini , creand histograme pentru zonele imaginii . Pasii de calculare ai histogramei sunt :

- redimensionarea imaginii la o forma standard de 128x64 pixeli
- calcularea gradientului, a magnitudinii si unghiul gradientului

Sobel

$$G_x \rightarrow \begin{bmatrix} -1 & 0 & 1 \\ -2 & \boxed{0} & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

$$G_y \rightarrow \begin{bmatrix} -1 & -2 & -1 \\ 0 & \boxed{0} & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

Prewitt

$$G_x \rightarrow \begin{bmatrix} -1 & 0 & 1 \\ -1 & \boxed{0} & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

$$G_y \rightarrow \begin{bmatrix} -1 & -1 & -1 \\ 0 & \boxed{0} & 0 \\ 1 & 1 & 1 \end{bmatrix}$$


- dupa ce obtinem gradientul pentru fiecare pixel, matricile sunt impartite in blocuri si se creeaza histograme ale gradientilor
- urmeaza normalizarea in recunoastrea faciale, care este utilizata pentru a pregati cadrele si a crea un cadru uniform pentru machine learning
- formarea histogramei finale a gradientilor orientate: un vector de caracteristici ce contine informatii despre pozitia ochilor, nasului , textura pielii , etc. Acest vector este rezultatul extragerii si sumarizarii informatiilor relevante din imaginea fetei .

- ultimul pas este clasificarea si detectia, unde se foloseste un algoritm de invatare pentru probleme de clasificare si regresie .

C. Haar Cascades


Detectarea obiectelor utilizand Haar feature-based cascade classifiers reprezinta o metoda machine learning unde o functie cascade este antrenata pe mai multe imagini pozitive si negative. Desi sunt antrenati sa identifice un singur tip de obiect, acesti clasificatori pot fi folositi in paralel, pentru a detecta de exemplu ochii si fata.

- **Algoritmul are nevoie de un set de imagini pozitive** (in care se regasesc expresii faciale) si unul de **imagini negative** (in care nu exista oameni) pentru a colecta Haar features (trasaturile). Acestea sunt extrase folosind blocuri de tipul:




Haar features sunt calculate prin scaderea sumei intensitatilor pixelilor din zona alba din cea a pixelilor din zona neagra. Deoarece acestea sunt greu de determinat pentru o imagine de mari dimensiuni, algoritmul foloseste integral images.

- **Creare integral images:** In loc de calcularea pentru fiecare pixel in parte, se vor crea subregiuni ale imaginii pentru care vom calcula trasaturile.



- **Adaboost alege cele mai bune trasaturi:** Se va folosi o combinatie de weak classifiers (metode de clasificare nu foarte precise, dar care pot sa dea rezultate importante folosite impreuna) pentru a crea un strong classifier pe care algoritmul il poate folosi pentru a detecta obiectele. Pentru a crea acesti clasificatori slabi, algoritmul va aplica ferestre peste imagine, calculand pentru fiecare in parte caracteristicile Haar. Acestea vor fi comparate cu un prag anterior, care separa fetele de restul obiectelor.

- **Combinarea acestor clasificatori slabi intr-un clasificator puternic** se realizeaza prin intermediul cascade classifiers.
- **Implementare Cascade Classifier:** este alcatuita dintr-o serie de stari, unde fiecare nivel este o colectie de weak classifiers. Fiecare nivel decide daca obiectul este sau nu o expresie faciala – positive: s-a identificat o fata, negative: cauta mai departe in urmatoorii classifiers. Este esential sa avem o rata cat mai mica de raspunsuri negative, deoarece afecteaza grav algoritmul de detectie.



D. AdaBoost

AdaBoost este un algoritm de invatare automata utilizat pentru clasificare si regresie . Acest algoritm construieste un model puternic prin combinarea unor modele de baza(weak learners). Metoda asociază o pondere fiecărui exemplu de antrenare. Inițial toate instanțele au aceeași pondere de $1/n$. Algoritmul se bazeaza pe ideea de a gasi clasificatorul slab cel mai bun pe baza erorii ponderate(cea mai mica valoare), apoi modificam importanta exemplorilor. Exemplele care au fost clasificate gresit vor avea o pondere mai mare, ceea ce le va face mai importante pentru urmatoorii clasificatori slabi, in timp ce exemplele care au fost clasificate corect vor avea o pondere mai mica. In urmatoorul pas vom descoperi un alt clasificator inefficient, deoarece trebuie sa clasifice corect instantele cu pondere mai mare, avand o parte mai mare din eroarea ponderata. Scorul final este influentat de fiecare clasificator slab. Aceasta influenta este evaluata in functie de cat de bine performeaza pe setul de antrenare.


E. SVM

Un instrument de învățare automată eficient cunoscut sub numele de SVM (Support Vector Machine) are capacitatea de a gestiona seturi de date extrem de complexe, de recunoaștere facială, inasa nu este practic in sistemele real-time. Practic, SVM cauta un hiperplan pe care il va plasa astfel incat distanta dintre 2 elemente sa fie maxima. Atunci cand introducem o noua data (o noua persoana), algoritmul va sti sa o plaseze in multimea corecta. CNN este mai precis decat SVM, fiind utilizat in prezent.

III. SOLUTII COMERCIALE

- Tehnologia Afectiva poate fi integrata in aplicatii care doresc sa includa functionalitati de recunoastere a emotiilor. Prin utilizarea unei camere web, Affectiva poate identifica atat fata, cat si punctele cheie ale acesteia, pentru a clasifica expresiile faciale in sapte emotii principale(furie, dezgust, frica, bucurie, tristete si surpriza). Aplicatia este destinata agentilor de publicitate care doresc sa testeze reactia consumatorilor la videoclipuri, reclame si

emisiuni tv. Rezultatele tehnologiei Affectiva sunt extrem de promitatoare avand in vedere parteneriatele cu Coca Cola si Mars. Este folosita de peste 70 la suta dintre companiile de publicitate.



- O alta aplicatie cunoscuta care utilizeaza recunoasterea faciala pentru detectarea si recunoastere emotiilor este Microsoft Emotion API. Aceasta poate identifica emotiile umane, cum ar fi bucurie, tristete, furie, dispret si altele, folosind expresiile faciale. Dezvoltatorii pot obtine rezultate privind emotiile din fetele media prin incarcarea imaginilor sau transmiterea fluxurilor video catre API-ul Microsoft Emotion.



IV. DESCRIEREA METODELOR

Algoritmii Haar Cascades si HOG(Histogram of Oriented Gradients) reprezinta tehnici de detectare a obiectelor. Aceste metode nu se ocupa de segmentarea fetei(identificarea contururilor), ci se concentreaza mai mult pe identificarea zonelor care ar putea contine fete. Scopul principal al algoritmilor de detectare a fetei, utilizati in face recognition nu este de a identifica si de a evidentia anumite contururi, ci mai degraba de a diferentia zonele cu fete, de cele fara. Pentru implementarea codului nostru, am folosit limbajul Python, impreuna cu biblioteca facerecognition (din dlib, foloseste CNN), functii din OpenCV si mediul de programare Colab. Am creat un nou folder pentru a pune imaginile pe care le-am selectat de pe site-uri web pentru a incepe procesarea. Am ales multiple fotografii cu aceleasi persoane, din ipostaze diferite sau care afiseaza diverse emotii, pentru a pune in evidenta posibilitatea recunoasterii si gruparii imaginilor. La rulare, codul va incadra intr-un chenar rosu expresia faciala

identificata in poza, urmand ca la final sa afiseze, in ordine, imaginile care contin aceeași persoană.

Dintre funcțiile din biblioteca cv2 amintim:

- **cv2.imread**: citește imaginea, primește ca argument path-ul
- **cv2.rectangle**: pentru afișarea chenarului
- **cv2.imshow**: pentru afișarea imaginii

Algoritm detectare fețe în imagini:

- 1. `facerecognition.facelocations`: returnează un array care conține lista de coordonate pentru fiecare față din lista de imagini
- 2. salvăm coordonatele pentru fiecare față din imagine într-un tuplu (top, right, bottom, left); acestea vor fi folosite la trasarea conturului cu roșu pentru a evidenția zona capului

Algoritm recunoaștere fețe și afișarea imaginilor în ordine:

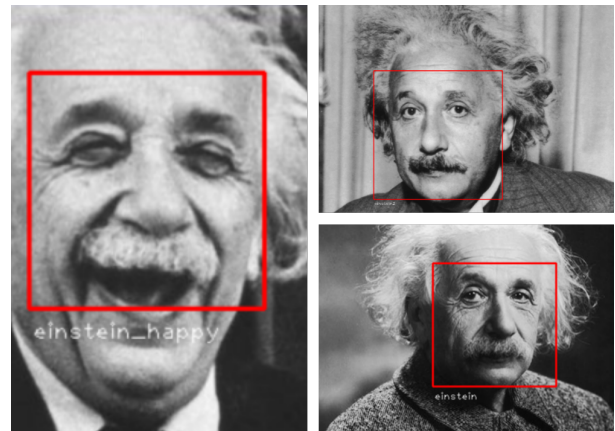
- 1. vom itera prin setul de date, adăugând într-o listă `knownnames` toate numele imaginilor;
- 2. pentru a afla dacă în imagini se repetă aceeași oameni, comparăm imaginile una câte una (prima cu a doua, cu a treia, șamd). Vom folosi funcția `comparefaces`, care primește ca argumente cele 2 imagini. Această funcție returnează un array de tip bool, comparând cele 2 array-uri ale funcției `facerecognition`; atunci când găsește valori comune sau foarte asemănătoare pe aceeași poziție, returnează True;
- 3. Dacă s-au găsit 2 imagini cu aceeași persoană, vom adăuga numele acesteia într-o listă doar o singură dată; Algoritmii de recunoaștere a fețelor din bibliotecă folosesc detectarea. În recunoașterea feței, detectarea se referă la procesul de a determina dacă o față este prezentă într-o imagine. Acest lucru implică găsirea zonelor care ar putea conține fețe, delimitându-le în dreptunghiuri. În ultima parte a codului, am evidențiat zonele de interes pentru algoritm, prin utilizarea funcției `facelandmarks`, care returnează coordonatele pentru diferite caracteristici ale feței (chin, left-eyebrow, nose-bridge, etc), mai apoi colorându-le cu funcția `fill` din `matplotlib.pyplot`.

V. REZULTATE PRELIMINARE


Rezultatele rularii:



Dacă s-au găsit mai multe imagini cu aceeași persoană, se vor afișa din nou doar imaginile în care apare persoana, împreună cu numele acesteia.



Rezultatul funcției `plotfacelandmarks`



VI. CONCLUZII PRELIMINARE

Asadar, pana in acest stadiu al proiectului am reusit sa identificam expresiile faciale ale persoanelor din fotografii, utilizand in principal functii din biblioteca facerecognition. De asemenea, algoritmul poate identifica si daca o persoana se regaseste de mai multe ori in setul de date. Provocarile tehnice intalnite in realizarea proiectului au fost:

- alegerea unui set de date clar, cu persoane cu fata lizibila
- cautarea bibliotecilor si incercarea de a intelege conceptele de machine learning utilizate

REFERENCES

- [1] P. Viola and M. Jones, "Rapid object detection using a boosted cascade of simple features," Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001, Kauai, HI, USA, 2001, pp. I-I, doi: 10.1109/CVPR.2001.990517.
- [2] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05), San Diego, CA, USA, 2005, pp. 886-893 vol. 1, doi: 10.1109/CVPR.2005.177.
- [3] S. Sriramprakash, Vadana D Prasanna, O.V. Ramana Murthy, Stress Detection in Working People, Procedia Computer Science, Volume 115, 2017, Pages 359-366, ISSN 1877-0509
- [4] Zhiming Xie et al 2019 J. Phys.: Conf. Ser. 1395 012006
- [5] P Ramesh Naidu et al 2021 J. Phys.: Conf. Ser. 2089 012039
- [6] Nijhawan, Tanya, Girija Attigeri, and T. Ananthakrishna. "Stress detection using natural language processing and machine learning over social interactions." Journal of Big Data 9.1 (2022): 1-24